Ekonometrija 1

Prvi seminar: *Uvod v programski paket Stata.*

Na prvem seminarju bomo najprej spoznali zasnovo in osnove dela s programskim paketom Stata. Srečali se bomo z dvema pristopoma k analizi podatkov. Na konkretnem primeru si bomo pogledali pregled in urejanje podatkov, kreiranje različnih diagramov, delo s skalarji in matrikami, transformiranje spremenljivk, uporabo statističnih porazdelitev in testiranje ničelnih hipotez. Nato si bomo pogledali še primer časovno serije, kjer se bomo osredotočili na opredelitev časovne dimenzije, kreiranje periodičnih komponent, uporabo nepravih spremenljivk in uporabo odlogov.



Primer 1: Na voljo imamo podatke za spremenljivke y, x_1 , x_2 in x_3 . Za navedene spremenljivke imamo po 8 opazovanj, kot je prikazano v tabeli. Podatki se že nahajajo v podatkovni datoteki osnove_state.dta, programska koda, ki jo boste potrebovali, pa v datoteki osnove state-ukazi.do.

i	1	2	3	4	5	6	7	8
y_i	2	2	1	5	-4	1	4	1
x_{1i}	1	1	1	1	1	1	1	1
x_{2i}	1	2	0	-1	1	-1	-2	0
x_{3i}	-1	-1	2	-4	3	0	2	-1

- a) Proučite podatke s pomočjo različnih ukazov za pregled podatkov. Kako bi najlažje ročno uredili podatke za konkretne spremenljivke in konkretna opazovanja v vaši bazi?
- b) Proučite podatke še grafično s pomočjo različnih diagramov. Uporabite razsevni diagram, linijski diagram in histogram.
- c) Na osnovi obstoječih spremenljivk iz podatkovne baze z različnimi transformacijami generirajte nekaj novih spremenljivk. Uporabite množenje, absolutne vrednosti, logaritmiranje, antilogaritmiranje ter standardiziranje.
- d) Prikličite iz Statinega spomina rezultate izvedbe enostavnejšega ukaza summarize ter kompleksnejšega ukaza regress. Kako bi jih shranili za kasnejšo uporabo?
- e) Prikažite kovariančno in korelacijsko matriko spremenljivk y, x_2 in x_3 . Ugotovite tudi statistično značilnost izračunanih korelacijskih koeficientov.

Izpis rezultatov obdelav v programskem paketu Stata:

a) Pregled podatkov

. describe

Contains data

Contains data
obs: 8
5

variable name	storage type	display format	value label	variable label
obs y x1 x2 x3	float float float float float	%9.0g %9.0g %9.0g %9.0g %9.0g		Opazovanje Spremenljivka y Spremenljivka x1 Spremenljivka x2 Spremenljivka x3

Sorted by:

Note: dataset has changed since last saved

. inspect x2

x2:	Spi	cem	enl	jivk	a x2			Nur	mber of Obse	ervations
								Total	Integers	Nonintegers
	#	‡	#	#			Negative	3	3	_
	#	‡	#	#			Zero	2	2	_
	#	‡	#	#			Positive	3	3	_
‡	# #	‡	#	#	#					
‡	# #	‡	#	#	#		Total	8	8	_
‡	# #	‡	#	#	#		Missing	_		
+										
-2						2		8		
	(5 ur	niq	ue '	valu	es)					

. sum y x1 x2 x3

Variable	Obs	Mean	Std. Dev.	Min	Max
У	8	1.5	2.672612	-4	5
x1	8	1	0	1	1
x2	8	0	1.309307	-2	2
x3	8	0	2.267787	-4	3

. sum y, detail

Spremenljivka y

		261 00111 21 11	200 1	
	Percentiles	Smallest		
1%	-4	-4		
5%	-4	1		
10%	-4	1	0bs	8
25%	1	1	Sum of Wgt.	8
50%	1.5		Mean	1.5
		Largest	Std. Dev.	2.672612
75%	3	2		
90%	5	2	Variance	7.142857
95%	5	4	Skewness	864
99%	5	5	Kurtosis	3.5344

. tabstat y x1 x2 x3, stat(N mean sd median sum min max)

stats	У	x1	x2	x3
N mean	8 1.5	8	8 0	8
sd	2.672612	0	1.309307	2.267787
p50	1.5	1	0	5
sum	12	8	0	0
min	-4	1	-2	-4
max	5	1	2	3

. tab y

Spremenljivka y	Freq.	Percent	Cum.
-4 1 2 4 5	1 3 2 1 1	12.50 37.50 25.00 12.50 12.50	12.50 50.00 75.00 87.50 100.00
Total	+ 8	100.00	

. tab y x3

Spremenljivka y		Sp:	remenljivka	x 3		
	-4	-1	0	2	3	Total
-4	+ 0	0	0	0	1	+ 1
1	j o	1	1	1	0	j 3
2	j 0	2	0	0	0	2
4	0	0	0	1	0	1
5] 1	0	0	0	0] 1
Total	+ 1	3	1	2	1	+ 8

. list, N mean sum

-	+			+
	 у	x1	x2	x3
1. 2. 3. 4.	 2 2 1 5	1 1 1 1 1	1 2 0 -1	-1 -1 -1 2 -4 3
٠.	 			
6. 7. 8.	1 4 1	1 1 1	-1 -2 0	0 2 -1
Mean Sum N	 1.5 12 8	1 8 8	0 0 8	 0

. list in 4/8


	У	x1		x3
4.	 5	1	-1	 -4
5.	-4	1	1	3

- . list x1 x2 if x2>=0

	+	+
	x1	x2
1.	1	1
2.	1	2
3.	1	0
5.	1	1
8.	1	0
	+	+


- b) Diagrami v Stati
- . twoway scatter y x2

. twoway scatter y obs




. twoway connected y obs


. twoway line y obs



. hist x2
(bin=2, start=-2, width=2)

. hist x2, bin(5) normal
(bin=5, start=-2, width=.8)





- c) Generiranje novih spremenljivk
- . gen yx2=100*y*x2
- . gen x2kv=x2^2
- . gen x2a=abs(x2)
- . gen lx2=log(x2)

(5 missing values generated)

. gen ex2=exp(lx2)

(5 missing values generated)

. list

-	+ у 	x1	x2	x3	obs	yx2	x2kv	x2a	1x2	ex2
1.	2	1	1	-1	1	200	1	1	0	1
2.	2	1	2	-1	2	400	4	2	.6931472	2
3.	1	1	0	2	3	0	0	0		
4.	5	1	-1	-4	4	-500	1	1		
5.	-4	1	1	3	5	-400	1	1	0	1
6.	 1	 1	 -1	0	 6	 -100	 1	 1		
	! -	1	-1 -2	•	7		1	2	•	•
7.	4	1	_	2		-800	4	2	•	•
8.	, <u> </u>	Т	0	-1	8	0	0	0	•	•

- . replace lx2=0 if lx2==.
- (5 real changes made)
- . egen x2s=std(x2)
- . list lx2 x2s

_		
	1x2	x2s
1.	0	.7637626
2.	.6931472	1.527525
3.	j 0	0

4.	0	7637626
5.	0	.7637626
6.	0	7637626
7.	0	-1.527525
8.	j 0	0

. drop obs yx2 x2kv x2a 1x2 ex2 x2s

d) Priklic podatkov iz Statinega spomina

. sum y

Variable	Obs	Mean	Std. Dev.	Min	Max
+	 8	1.5	 2 672612	 -4	

. return list

scalars:

r(N) = 8r(sum_w) = 8 r(mean) = 1.5

r(Var) = 7.142857142857143 r(sd) = 2.672612419124244 r(min) = -4 r(max) = 5 r(sum) = 12

. regress y x2 x3

Source	SS	df	MS		Number of obs F(2, 5)		8 4.54
Model Residual	32.25 17.75	2 5	16.125 3.55		Prob > F R-squared Adj R-squared	= =	0.0751 0.6450 0.5030
Total	50	7	7.14285714		Root MSE	=	1.8841
У	Coef.	Std. E	Err. t	P> t	[95% Conf.	In	terval]
x2 x3 _cons	-1 75 1.5	.54390 .31402 .66614	241 -2.39	0.063	-2.398154 -1.557225 2123819		3981539 0572245 .212382

. ereturn list

scalars:

e(N) = 8e(N) = 6 e(df_m) = 2 e(df_r) = 5 e(F) = 4.542253521126761 e(r2) = .645 e(rmse) = 1.884144368141677

e(mss) = 32.25e(rss) = 17.75

 $e(r2_a) = .503$ e(11) = -14.53928416260374 $e(11_0) = -18.68183412063062$

e(rank) = 3

macros:

e(cmdline) : "regress y x2 x3"
 e(title) : "Linear regression"

e(marginsok) : "XB default"

e(vce) : "ols"

e(depvar): "y"
e(cmd): "regress"
e(properties): "b V" e(predict) : "regres_p" e(model) : "ols"

e(estat_cmd) : "regress_estat"

matrices:

 $e(b) : 1 \times 3$ $e(V) : 3 \times 3$

functions:

e(sample)

- . scalar r2=e(r2)
- . display r2

.645

- . matrix varcov=e(V)
- . matrix list varcov

symmetric varcov[3,3]

x2 x3 _cons x2 .29583333 x3 0 .09861111 0 0 .44375 _cons

- . scalar varcov22=varcov[2,2]
- . display varcov22
- .09861111
- e) Kovariance in korelacija
- . correlate y x2 x3, covariance (obs=8)

	У	x2	x3
x2	7.14286 -1.71429 -3.85714		5.14286

. correlate y x2 x3

(obs=8)

y x2 x3 y | 1.0000 x2 | -0.4899 1.0000 x3 | -0.6364 0.0000 1.0000

. pwcorr y x2 x3, sig

	У	x2	x3
У	1.0000		
x2	 -0.4899 0.2178	1.0000	
x 3	 -0.6364 0.0898	0.0000	1.0000

. clear all

<u>Primer 2:</u> V priloženi podatkovni datoteki osnove_casovnih_vrst.dta se nahaja časovna vrsta z začetkom v letu 1950. Programska koda, ki jo boste potrebovali, se nahaja v datoteki osnove_casovnih_vrst-ukazi.do.

- a) Odprite v programskem paketu Stata podatkovno datoteko. Proučite podatke s pomočjo različnih ukazov za pregled podatkov.
- b) Opredelite časovno dimenzijo podatkov. Nato sortirajte podatkovno bazo po časovni dimenziji ter zamenjajte vrstni red spremenljivk. Generirajte trend, neprave spremenljivke za četrtletja in ciklično komponento.
- c) Generirajte nepravo spremenljivko, ki zavzame vrednost 1, če ima naša spremenljivka vrednost, ki je večja ali enaka 80 % njene mediane ali pa manjša od dveh tretjin njene aritmetične sredine, v ostalih primerih pa zavzame vrednost 0.
- d) Generirajte prve in četrte odloge naše spremenljivke ter druge vodeče odloge. Generirajte še prve diference naše spremenljivke.

Izpis rezultatov obdelav v programskem paketu Stata:

a) Pregled podatkov

. inspect spr

spr:	Caso	ovna	spr	emenlji [.]	vka	(v enotah mere)	Number of Observations			
							Total	Integers	Nonintegers	
#						Negative	_	_	_	
#						Zero	_	_	-	
j #	#					Positive	204	18	186	
#	#	#	#							
#	#	#	#			Total	204	18	186	
#	#	#	#	#		Missing	-			
+										
1610.	5			9303.9			204			
(More	thar	n 99	uni	que val	ues)					

. tabstat spr, stat(N mean sd median sum min max)

variable	N	mean	sd	p50	sum	min	max
spr	204	4562.646	2113.962	4142.2	930779.7	1610.5	9303.9

b) Opredelitev casovne dimenzije in generiranje periodicnih komponent

. tsset kvartal

time variable: kvartal, 1950q1 to 2000q4 delta: 1 quarter

- . sort kvartal
- order kvartal, lastorder kvartal, first
- . gen t=_n
- . gen q=quarter(dofq(kvartal))

. tabulate q, gen(d)

đ	Freq.	Percent	Cum.
1	+ 51	25.00	25.00
2	51	25.00	50.00
3	51	25.00	75.00
4	51	25.00	100.00
	+		
Total	204	100.00	

- . drop q
- . gen t2=t^2
- . gen t3=t^3

. list

_	+								+
	kvartal	spr	t	d1	d2	d3	d4	t2	t3
1.	 1950q1	1610.5	1	1	0	0	0	1	1
2.	1950q2	1658.8	2	0	1	0	0	4	8
3.	1950q3	1723	3	0	0	1	0	9	27
4.	1950q4	1753.9	4	0	0	0	1	16	64
5.	1951q1	1773.5	5	1	0	0	0	25	125
6.	 1951q2	1803.7	6	0	1	0	0	36	216
7.	1951q3	1839.8	7	0	0	1	0	49	343
8.	1951q4	1843.3	8	0	0	0	1	64	512
9.	1952q1	1864.7	9	1	0	0	0	81	729
10.	1952q2	1866.2	10	0	1	0	0	100	1000
11.	1952q3	1878	11	0	0	1	0	121	1331
12.	1952q4	1940.2	12	0	0	0	1	144	1728
13.	1953q1	1976	13	1	0	0	0	169	2197
14.	1953q2	1992.2	14	0	1	0	0	196	2744
15.	1953q3	1979.5	15	0	0	1	0	225	3375
16.	 1953q4	 1947.8	16	0	0	0	 1	256	4096
17.	1954q1	1938.1	17	1	0	0	0	289	4913

189.	1997q1	8016.4	189	1	0	0	0	35721	6751269	
190.	1997q2 	8131.9 	190 	0	1 	0	0	36100 	6859000	l
191.	1997q3	8216.6	191	0	0	1	0	36481	6967871	İ
192.	1997q4	8272.9	192	0	0	0	1	36864	7077888	ĺ
193.	1998q1	8396.3	193	1	0	0	0	37249	7189057	
194.	1998q2	8442.9	194	0	1	0	0	37636	7301384	
195.	1998q3	8528.5	195	0	0	1	0	38025	7414875	
196.	1998q4	8667.9	196	0	0	0	1	38416	7529536	
197.	1999q1	8733.5	197	1	0	0	0	38809	7645373	
198.	1999q2	8771.2	198	0	1	0	0	39204	7762392	
199.	1999q3	8871.5	199	0	0	1	0	39601	7880599	
200.	1999q4	9049.9	200	0	0	0	1	40000	8000000	
201.	2000q1	9102.5	201	1	0	0	0	40401	8120601	
202.	2000q2	9229.4	202	0	1	0	0	40804	8242408	
203.	2000q3	9260.1	203	0	0	1	0	41209	8365427	
204.	2000q4	9303.9	204	0	0	0	1	41616	8489664	
_	+									+

. keep kvartal spr

c) Generiranje neprave spremenljivke

. sum spr, detail

Casovna spremenljivka (v enotah mere)

	Percentiles	Smallest		
1%	1723	1610.5		
5%	1878	1658.8		
10%	2058.1	1723	0bs	204
25%	2600.05	1753.9	Sum of wgt.	204
50%	4142.2		Mean	4562.646
300	11 12.2	Largest	Std. dev.	2113.962
75%	6312.85	9102.5		
90%	7621.9	9229.4	Variance	4468837
95%	8442.9	9260.1	Skewness	.4680201
99%	9229.4	9303.9	Kurtosis	2.133958

. return list

scalars:

r(N) = 204
r(sum_w) = 204
r(mean) = 4562.645581413718
r(Var) = 4468836.741843408
r(sd) = 2113.962332172314
r(skewness) = .4680200721224719
r(kurtosis) = 2.133957959862034
r(sum) = 930779.6986083984
r(min) = 1610.5
r(max) = 9303.900390625
r(p1) = 1723
r(p5) = 1878
r(p10) = 2058.10009765625
r(p25) = 2600.050048828125
r(p50) = 4142.199951171875
r(p75) = 6312.849853515625
r(p90) = 7621.89990234375
r(p95) = 8442.900390625
r(p99) = 9229.400390625

- . gen d=0
- . replace d=1 if spr>=0.8*r(p50) | spr<(2/3)*r(mean)</pre>

(195 real changes made)

. tab d

Cum.	Percent	Freq.	d
4.41 100.00	4.41 95.59	9 195	0 1
	100.00	204	Total

- . drop d
- d) Generiranje odlozenih in vodecih spremenljivk
- . sort kvartal
- . gen spr_lag1=1.spr

(1 missing value generated)

. gen spr_lag4=14.spr

(4 missing values generated)

- . gen spr_lead2=f2.spr
- (2 missing values generated)
- . gen spr_diff1=d.spr
- (1 missing value generated)

. list

-	+ kvartal 	spr	spr_lag1	spr_lag4	spr_lead2	 spr_diff1
1. 2. 3. 4. 5.	1950q1 1950q2 1950q3 1950q4 1951q1	1610.5 1658.8 1723 1753.9 1773.5	1610.5 1658.8 1723 1753.9	1610.5	1723 1753.9 1773.5 1803.7 1839.8	. 48.30005 64.19995 30.90002 19.59998
6. 7. 8. 9.		1803.7 1839.8 1843.3 1864.7	1773.5 1803.7 1839.8 1843.3 1864.7	1658.8 1723 1753.9 1773.5 1803.7	1843.3 1864.7 1866.2 1878 1940.2	30.19995 36.1001 3.5 21.3999 1.5
11. 12. 13. 14. 15.	1952q3 1952q4 1953q1 1953q2 1953q3	1878 1940.2 1976 1992.2 1979.5	1866.2 1878 1940.2 1976 1992.2	1839.8 1843.3 1864.7 1866.2 1878	1976 1992.2 1979.5 1947.8 1938.1	11.80005 62.19995 35.80005 16.19995 -12.69995
16. 17. 18. 19. 20.	1953q4 1954q1 1954q2 1954q3 1954q4	1947.8 1938.1 1941 1962 2000.9	1979.5 1947.8 1938.1 1941 1962	1940.2 1976 1992.2 1979.5 1947.8	1941 1962 2000.9 2058.1 2091	-31.69995 -9.700073 2.900024 21 38.90002
21. 22.	 1955q1 1955q2	2058.1 2091	2000.9 2058.1	1938.1 1941	2118.9 2130.1	57.20007 32.8999

. . .

183.	1995q3	7561.4	7503.3	7370.2	7676.4	58.1001
184.	1995q4	7621.9	7561.4	7461.1	7802.9	60.5
185.	1996q1	7676.4	7621.9	7488.7	7841.9	54.5
186. 187. 188. 189.	1996q2 1996q3 1996q4 1997q1 1997q2	7802.9 7841.9 7931.3 8016.4 8131.9	7676.4 7802.9 7841.9 7931.3 8016.4	7503.3 7561.4 7621.9 7676.4 7802.9	7931.3 8016.4 8131.9 8216.6 8272.9	126.5 39 89.3999 85.1001 115.5
191.	1997q3	8216.6	8131.9	7841.9	8396.3	84.69971
192.	1997q4	8272.9	8216.6	7931.3	8442.9	56.30078
193.	1998q1	8396.3	8272.9	8016.4	8528.5	123.3994
194.	1998q2	8442.9	8396.3	8131.9	8667.9	46.60059
195.	1998q3	8528.5	8442.9	8216.6	8733.5	85.59961
196.	1998q4	8667.9	8528.5	8272.9	8771.2	139.4004
197.	1999q1	8733.5	8667.9	8396.3	8871.5	65.59961
198.	1999q2	8771.2	8733.5	8442.9	9049.9	37.7002
199.	1999q3	8871.5	8771.2	8528.5	9102.5	100.2998
200.	1999q4	9049.9	8871.5	8667.9	9229.4	178.4004
201. 202. 203. 204.	2000q1 2000q2 2000q3 2000q4	9102.5 9229.4 9260.1 9303.9	9049.9 9102.5 9229.4 9260.1	8733.5 8771.2 8871.5 9049.9	9260.1 9303.9	52.59961 126.9004 30.69922 43.80078

. clear all

12